



**UNIVERSITATEA DIN BUCUREȘTI**  
**FACULTATEA DE**  
**MATEMATICĂ ȘI INFORMATICĂ**



**SPECIALIZAREA INFORMATICĂ**

**Lucrare de licență**

# **RECUNOAȘTEREA EMOȚIILOR PRINTR-O ABORDARE MULTIMODALĂ**

**Coordonator științific:**

Conf. Univ. Dr. Alexe Dumitru-Bogdan

**Absolvent:**

Ionașcu Andrei

**București, iunie 2026**

# Rezumat

Această lucrare investighează recunoașterea emoțiilor printr-o abordare multimodală în scenarii conversaționale, punând accentul pe explicabilitate în interpretarea rezultatelor. Scopul este de a înțelege cum performează modelele unimodale bazate pe text, audio și imagine și cum pot fi acestea fuzionate pentru a îmbunătăți performanța. De asemenea, se compară performanța a două tipuri de modele pentru fiecare modalitate, unul complex și unul eficient, pentru a determina în ce măsură alternativele cu dimensiuni reduse se pot apropia de variantele complexe. Experimentele sunt realizate pe setul de date MELD, ce conține cadre extrase din serialul *Friends*, etichetate cu 7 categorii de emoții: anger (furie), disgust (dezgust), fear (frică), happiness (fericire), neutral (neutru), sadness (tristețe) și surprise (surpriză). Datele de tip text și audio sunt în limba engleză.

Au fost antrenate șase arhitecturi unimodale pe setul de date MELD: BERT-base și DistilBERT pentru text, ViT-B/16 și MobileNetV3-Small pentru imagine, respectiv wav2vec2-base și DistilHuBERT pentru audio. Au fost folosite trei moduri de fuziune: fuziune târzie, cu medie aritmetică și ponderată, fuziune intermediară bazată pe MLP și fuziune bazată pe porți, fiecare fiind aplicat atât pe cele trei modele complexe, cât și pe cele trei modele eficiente.

Arhitectura cea mai performantă a fost cea care folosea fuziunea târzie cu medie ponderată între modelele complexe, obținând un scor macro-F1 de 45.97%, urmată îndeaproape de fuziunea intermediară bazată pe MLP, cu un scor macro-F1 de 45.33%. Dintre modelele unimodale, cele pe text au avut cele mai bune rezultate, cu DistilBERT foarte aproape de BERT, reducând în același timp resursele necesare: 44.28% față de 41.23%. Metrica principală folosită pentru evaluarea modelelor a fost macro-F1, pentru a încuraja modelele să învețe reprezentări și pentru clasele cu foarte puține date, precum disgust și fear.

Partea de explicabilitate a fost implementată folosind diverse metode, printre care Integrated Gradients ca punct comun între modalități, urmând ca fiecare să aibă și o metodă particulară tipului de date. Eficiența a fost evidențiată folosind consumul de energie la antrenare și timpul de inferență per eșantion.

# Cuprins

|          |                                                                |           |
|----------|----------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introducere</b>                                             | <b>1</b>  |
| 1.1      | Context și motivație . . . . .                                 | 1         |
| 1.2      | Problema: explicabilitate și eficiență . . . . .               | 1         |
| 1.2.1    | Explicabilitatea rezultatelor . . . . .                        | 1         |
| 1.2.2    | Eficiența modelelor . . . . .                                  | 2         |
| 1.3      | Contribuții și obiective . . . . .                             | 2         |
| 1.3.1    | Preprocesarea datelor . . . . .                                | 2         |
| 1.3.2    | Integrarea multimodalității . . . . .                          | 2         |
| 1.3.3    | Explicabilitatea rezultatelor . . . . .                        | 3         |
| 1.3.4    | Compromisul dintre acuratețe și eficiență energetică . . . . . | 3         |
| <b>2</b> | <b>Setul de date și metodologia propusă</b>                    | <b>4</b>  |
| 2.1      | Setul de date MELD . . . . .                                   | 4         |
| 2.2      | Preprocesarea datelor . . . . .                                | 5         |
| 2.3      | Arhitecturile unimodale antrenate . . . . .                    | 7         |
| 2.4      | Strategiile de fuziune implementate . . . . .                  | 7         |
| 2.5      | Metodele de explicabilitate utilizate . . . . .                | 7         |
| 2.6      | Măsurarea eficienței . . . . .                                 | 8         |
| <b>3</b> | <b>Implementare și configurare experimentală</b>               | <b>9</b>  |
| 3.1      | Tehnologii utilizate . . . . .                                 | 9         |
| 3.2      | Structura implementării . . . . .                              | 9         |
| 3.3      | Antrenarea modelelor . . . . .                                 | 10        |
| 3.4      | Metrici de evaluare . . . . .                                  | 11        |
| <b>4</b> | <b>Rezultate experimentale și evaluare</b>                     | <b>12</b> |
| 4.1      | Performanța generală . . . . .                                 | 12        |
| 4.2      | Analiza matricelor de confuzie . . . . .                       | 13        |
| 4.2.1    | Modele unimodale complexe și eficiente . . . . .               | 14        |
| 4.2.2    | Comparația dintre fuziunile complexe și eficiente . . . . .    | 14        |
| 4.3      | Analiza XAI pe cazuri generale . . . . .                       | 17        |
| 4.3.1    | Text . . . . .                                                 | 17        |
| 4.3.2    | Audio . . . . .                                                | 17        |
| 4.3.3    | Imagine . . . . .                                              | 17        |
| 4.4      | Analiza eficienței . . . . .                                   | 18        |
| <b>5</b> | <b>Concluzii și direcții viitoare</b>                          | <b>20</b> |

# 1 Introducere

## 1.1 Context și motivație

Recunoașterea emoțiilor a evoluat de-a lungul timpului, plecând de la fluxuri convenționale, bazate pe caracteristici extrase manual pentru fiecare modalitate în parte, către arhitecturi de tip deep learning, adesea pre-antrenate, capabile să modeleze contextul, structura temporală și interacțiunile cross-modale, după cum detaliază [1]. Pe partea de audio și vorbire, domeniul a migrat de la descriptori clasici și clasificatori simpli către modelele CNN-LSTM aplicate semnalului brut (raw waveform) [2] și, ulterior, către codificatori de vorbire self-supervised, precum wave2vec 2.0 [3]. În vederea artificială (computer vision), traiectoria pornește de la descriptori de textură, precum Local Binary Patterns [4], și ajunge la rețele convoluționale, rețele bazate pe mecanisme de atenție [5] și modele FER optimizate pentru dispozitive de tip embedded [6]. Procesarea limbajului natural cu scopul recunoașterii emoțiilor a evoluat de la sisteme bazate pe lexicon și seturi de date restrânse [7], la preantrenarea slab supervizată și fine-tuning a modelelor de tip Transformer [8] pe corpuri masive de date, cum este GoEmotions [9]. Pe lângă modalitățile clasice, studiile recente explorează ramura de informatică fiziologică, unde lucrările fundamentale s-au concentrat pe semnale EEG (Electroencefalogramă) și periferice, utilizând seturi de date de referință precum DEAP [10], progresând recent către modele grafice care analizează topologia semnalelor cerebrale [11].

Motivația acestei cercetări vine de la interesul tot mai mare pentru dezvoltarea sistemelor capabile să înțeleagă emoții în contexte conversaționale reale. Deși modelele moderne de inteligență artificială obțin performanțe ridicate în recunoașterea emoțiilor, rezultatele acestora sunt dificil de interpretat și necesită resurse computaționale semnificative. În plus, utilizarea unei singure modalități de intrare, precum text sau video, este de multe ori insuficientă pentru surprinderea completă a stării emoționale.

Prin urmare, această lucrare își propune să analizeze performanța modelelor de diferite dimensiuni în același context, evidențiind compromisul dintre acuratețe și eficiență energetică și de timp. De asemenea, se evidențiază și îmbunătățirea pe care o aduce fuziunea modalităților, urmărind în paralel și vizualizarea într-un mod cât mai explicit a rezultatelor obținute de arhitecturi.

## 1.2 Problema: explicabilitate și eficiență

### 1.2.1 Explicabilitatea rezultatelor

Vasta majoritate a publicațiilor științifice din domeniul recunoașterii emoțiilor au ca scop obținerea unei precizii cât mai mari. Totuși, complexitatea necesară maximizării acurateții duce adesea la modele de tip *black-box*, al căror mecanism intern de decizie este prea complicat pentru a fi înțeles chiar de către oameni de știință [12, 13], cu atât mai puțin de către utilizatorul

obișnuit. Înțelegerea procesului de *reasoning* este esențială pentru evaluarea încrederii într-un sistem și pentru decizia de a-l utiliza sau implementa în practică [14]. Prin urmare, opacitatea modelelor poate contribui la scăderea încrederii în progresul tehnologic și la reticența față de adoptarea unor produse bazate pe inteligență artificială [13].

În această lucrare, explicabilitatea nu este tratată separat de evaluarea performanței, ci este integrată în interpretarea rezultatelor obținute de modelele unimodale și multimodale. Scopul este de a înțelege nu doar care arhitectură obține cele mai bune scoruri, ci și ce informații par să fie folosite de fiecare modalitate în procesul de decizie. Astfel, metodele de explicabilitate sunt utilizate pentru a analiza punctele forte și limitele modelelor bazate pe text, audio și imagine, precum și efectul strategiilor de fuziune asupra interpretării finale.

### **1.2.2 Eficiența modelelor**

Complexitatea modelelor State-of-the-Art presupune, în majoritatea cazurilor, un cost computațional ridicat [15]. Dincolo de performanța brută, timpul de inferență devine un criteriu important atunci când modelele sunt utilizate în scenarii practice, mai ales pe dispozitive cu resurse limitate. În astfel de contexte, cum sunt dispozitivele de tip edge, un model mai rapid și mai compact poate fi preferabil unei arhitecturi mai complexe, chiar dacă diferența de performanță este redusă.

Prin urmare, această lucrare analizează și compromisul dintre acuratețe și eficiență, urmărind în ce măsură modelele cu dimensiuni reduse se pot apropia de performanța variantelor complexe. Această perspectivă este relevantă pentru evaluarea portabilității modelelor și pentru utilizarea lor în aplicații unde timpul rapid de inferență este important [16]. În plus, eficiența este discutată împreună cu rezultatele experimentale, pentru a evidenția dacă îmbunătățirile obținute prin fuziune justifică resursele suplimentare necesare.

## **1.3 Contribuții și obiective**

### **1.3.1 Preprocesarea datelor**

La nivel de text și sunet, preprocesarea datelor a fost minimală, rezumându-se doar la schimbări destinate uniformizării și compatibilității cu modelele antrenate. În schimb, în cazul imaginilor, datorită faptului că MELD vine cu secvențe video, a fost necesar un flux de procesare pentru extragerea cadrelor, decuparea fețelor și alegerea celor mai apropiate de emoția etichetată, pentru a obține un set de date de FER cât mai curat. Fiecare cadru este asociat cu înregistrarea și textul dialogului din care a fost extras.

### **1.3.2 Integrarea multimodalității**

Au fost implementate trei tehnici de fuziune a modalităților: fuziune târzie, fuziune intermediară și fuziune bazată pe porți. Fuziunea târzie combină probabilitățile softmax prin două me-

tode, o medie aritmetică și o medie ponderată optimizată pe datele de validare, fără a fi necesară o reantrenare. Fuziunea intermediară extrage penultimele reprezentări vectoriale din rețelele preantrenate și antrenează un perceptron multistrat ușor (MLP), de proiecție (334-367K parametri). Fuziunea bazată pe porți este similară cu fuziunea târzie, doar că ponderile se calculează pentru fiecare eșantion.

### **1.3.3 Explicabilitatea rezultatelor**

Pentru a transparentiza modelele, au fost folosite diverse metode de explicare și vizualizare, specifice fiecărei modalități. Ca punct comun, este folosit algoritmul Integrated Gradients [17] pe toate cele trei modalități, fiecare având adițional câte o metodă de explicabilitate specifică: ocluzia tokenilor pentru text, ocluzia temporală pentru audio [18] și Grad-CAM [19] pentru imagini. În funcție de model, metodele mai ușor de vizualizat au fost alese pentru a fi incluse în lucrare.

### **1.3.4 Compromisul dintre acuratețe și eficiență energetică**

Pentru fiecare modalitate au fost folosite două modele, unul cu un număr de parametri mai mare, cu scopul de a obține o acuratețe cât mai bună, iar unul cu un număr semnificativ mai mic, în funcție de modalitate, care are ca scop reducerea resurselor folosite, menținând pe cât posibil acuratețea la un nivel cât mai apropiat.

## 2 Setul de date și metodologia propusă

### 2.1 Setul de date MELD

Dezvoltarea sistemelor de recunoaștere a emoțiilor este puternic dependentă de seturile de date disponibile. În condițiile în care emoțiile sunt un aspect complex al comportamentului uman, iar transmiterea lor se realizează pe căi multiple, seturile de date trebuie să reflecte acest lucru. Urmând evoluția algoritmilor, seturile de date destinate recunoașterii emoțiilor au pornit de la variante unimodale și au ajuns treptat la variante multimodale.

Un exemplu des întâlnit este IEMOCAP. Acesta conține aproximativ 12 ore de date audiovizuale, incluzând înregistrări audio, capturi video și transcrieri, colectate într-un mediu controlat, din interacțiuni între actori [20]. Deși foarte util, acest set de date nu reușește să reflecte complet lipsa de predictibilitate și de structură a interacțiunilor reale, ducând la rezultate artificial mai mari prin natura controlată a interacțiunilor.

În acest context, MELD reprezintă o alternativă care reflectă mai bine scenarii conversaționale apropiate de cele reale. MELD, sau Multimodal EmotionLines Dataset, a fost introdus ca o extensie a setului de date EmotionLines și este construit din fragmente din serialul *Friends*. Acesta conține peste 1.400 de dialoguri și aproximativ 13.000 de replici, fiecare adnotată cu etichete de emoții [21]. Sunt folosite șapte etichete: furie(anger), dezgust(disgust), frică(fear), fericire(joy), neutru(neutral), tristețe(sadness) și surpriză(surprise), iar pentru consistență între modele, joy a fost înlocuit cu happiness. Dialogurile sunt integral în limba engleză.

Principalele provocări în recunoașterea emoțiilor pe MELD sunt legate de zgomotul prezent în date. Replicile sunt de multe ori sarcastice, textul având alt înțeles decât cel aparent. Pe fundal sunt adăugate râsete, care pot induce modelele audio în eroare. În cazul imaginilor, fețele personajelor care vorbesc nu sunt întotdeauna centrate în cadru, ceea ce face dificilă extragerea feței vorbitorului. Totuși, deși aceste lucruri afectează puternic scorul final, natura mai apropiată de scenarii reale a lui MELD oferă încrederea că modelele care produc rezultate bune în teste pot avea un comportament mai apropiat de cel necesar în aplicații practice.

Este important să evidențiem principalele provocări ale setului de date, întrucât acesta afectează direct și substanțial rezultatele. Analiza din Tabelul 2.1 a fost făcută pe întreg setul de date și ia în considerare distribuția emoțiilor, lungimea în cuvinte a replicilor și durata înregistrării audio folosite. Distribuția emoțiilor arată un dezechilibru clar între clase, neutral fiind dominantă cu 47% din replici, în timp ce disgust și fear au sub 3%. În consecință, acuratețea este insuficientă dacă ne propunem să stabilim cât de bine detectează modelele emoțiile, motiv pentru care am optat în această lucrare pentru scorul macro-F1.

| Emotie   | Dialog (%)    | Lungimea textului $\mu \pm \sigma$ / median | Durata inregistrării $\mu \pm \sigma$ / median |
|----------|---------------|---------------------------------------------|------------------------------------------------|
| Furie    | 1,607 (11.7%) | $9.2 \pm 6.5$ / 8                           | $3.28 \pm 2.16$ / 2.75 s                       |
| Dezgust  | 361 (2.6%)    | $10.0 \pm 6.9$ / 8                          | $3.69 \pm 2.32$ / 3.05 s                       |
| Frică    | 358 (2.6%)    | $9.3 \pm 6.3$ / 8                           | $3.26 \pm 2.16$ / 2.63 s                       |
| Fericire | 2,308 (16.8%) | $7.7 \pm 6.0$ / 6                           | $3.16 \pm 2.29$ / 2.50 s                       |
| Neutru   | 6,436 (47.0%) | $7.8 \pm 6.2$ / 6                           | $2.97 \pm 2.11$ / 2.38 s                       |
| Tristețe | 1,002 (7.3%)  | $10.0 \pm 7.0$ / 9                          | $3.71 \pm 2.41$ / 2.96 s                       |
| Surpriză | 1,636 (11.9%) | $6.0 \pm 5.0$ / 5                           | $2.67 \pm 2.04$ / 2.05 s                       |

Tabelul 1: Statistici MELD per emotie. Secvențele audio au fost truncate la 10s.

## 2.2 Preprocesarea datelor

Pentru modelele de text, replicile au fost tokenizate folosind AutoTokenizer din biblioteca Hugging Face, cu o lungime maximă de 128 de tokeni. Pentru modelele bazate pe sunet, înregistrările de 16 kHz sunt încărcate folosind torchaudio și trunchiate la maximum 10 secunde. Înregistrările sunt apoi trecute prin AutoFeatureExtractor pentru normalizare înainte de a fi procesate de model.

Deoarece MELD conține secvențe video, din motive de eficiență, sunt extrase cadre la un pas temporal fix din fiecare clip. Provocarea este dată de faptul că fiecare clip poate conține mai mulți actori, cadre fără față vizibilă sau momente în care personajul nu exprimă emoția dominantă. Fluxul de procesare, descris în Figura 1 rezolvă această problemă printr-o selecție inteligentă a cadrelor: extrage primele cinci cadre reprezentative per replică, prioritizând cadrele în care emoția transcrisă este vizibil prezentă pe fața vorbitorului.




Figura 1: Procesul de extragere al fețelor din videoclipuri

În prima fază, pentru a reduce timpul de procesare fără a pierde informație, se folosește un pas temporal de 3, ceea ce presupune extragerea unui cadru din trei. Acest lucru menține acoperirea temporală, deoarece cadrele adiacente sunt de obicei aproape identice. Fiecare cadru

eșantionat este apoi trecut prin MTCNN, o rețea cu trei etape, P-Net, R-Net și O-Net, care returnează ferestre de localizare și scoruri de încredere pentru toate fețele din cadru [22]. Alegerea MTCNN este motivată de robustețea pe imagini din medii naturale, precum televiziune și film, și de capacitatea de a detecta fețe în orientări variate [22]. Alternativa mai simplă și rapidă, Haar Cascade, ar fi semnificativ mai imprecisă în acest caz particular.

MTCNN este folosit cu `keep_all=True` pentru a obține toate fețele din cadru, lucru necesar pentru pasul de selecție a vorbitorului. Dacă MTCNN nu detectează nicio față în cadrul curent, acesta este omis. Următorul pas constă în extragerea feței vorbitorului. Acest lucru se face folosind două moduri. Din primul cadru, se extrage singura față dacă este doar una sau fața cu suprafața cea mai mare din cadru dacă sunt mai multe. Reprezentările vectoriale ale acestei fețe sunt salvate ca reprezentare a personajului, urmând ca ulterior, pentru fiecare cadru cu mai multe fețe, vorbitorul să fie ales folosind similaritatea cosinus cu reprezentarea salvată, în locul euristicii bazate doar pe dimensiune.

De menționat este că această abordare presupune riscul ca prima față detectată să nu fie a vorbitorului, caz în care cadrele extrase pot fi greșite. Fundamentul alegerii stă totuși în practicile de filmare ale serialelor, unde vorbitorul este pus frecvent în prim-plan, cel puțin la începutul replicii. Pentru a compensa eventualele valori extreme, resetarea reprezentărilor se face la nivel de partiție a setului de date, astfel încât un personaj greșit apărut la începutul unui clip să nu afecteze întregul proces.

După extragerea fețelor, fereastra de localizare este extinsă cu un factor de 1.2 față de centrul său, apoi decupată la marginile imaginii. Dacă dimensiunea este sub 48 px, cadrul este ignorat din cauza limitării modelelor de a extrage trăsături semnificative. Extinderea de 20% ajută la captarea gâtului și a frunții, contexte vizuale relevante pentru emoție.

Pentru a curăța datele, fiecare față este trecută prin `enet_b0_8_best_afew`[6, 23], un model EfficientNet-B0. Modelul returnează probabilități pentru opt clase; clasa Contempt este ignorată deoarece nu face parte din etichetele folosite în MELD. Scorul unui cadru este calculat ca produs între probabilitatea clasei corecte, conform fișierului CSV de metadate, și probabilitatea maximă acordată de model, indiferent de clasă. Acest mod de a calcula scorul a fost ales deoarece cadrele utile sunt cele în care modelul nu doar că prezice corect, ci are și un nivel ridicat de încredere în predicție. EfficientNet-B0, fiind antrenat pe AFEW, este conceput specific pentru emoții din materiale video, ceea ce îl face potrivit pentru specificul MELD [24, 23].

În final, scorurile per replică sunt netezite cu un filtru gaussian 1D cu sigma 0.5 pentru a reduce numărul vârfurilor false. Sunt selectate primele  $K=5$  cadre în funcție de scorul calculat după metodologia descrisă anterior, acestea fiind salvate ca date de antrenare.  $K=5$  reprezintă un compromis între un număr insuficient de imagini pentru extragerea trăsăturilor relevante și supradimensionarea setului de date cu imagini irelevante sau aproape identice între ele.

## 2.3 Arhitecturile unimodale antrenate

Au fost selectate șase modele unimodale pentru a fi adaptate pe setul de date MELD. Fiecare modalitate are un model orientat pe acuratețe și unul orientat pe eficiență. Ele au fost alese în funcție de o serie de factori, printre care cei mai importanți sunt comparabilitatea intra-modală și posibilitatea antrenării pe un echipament hardware limitat. Această combinație face posibilă evidențierea compromisului între eficiență și acuratețe, pe diferențe mai mici sau mai mari în funcție de modalitate, arătând că uneori, cu mult mai puține resurse, pot fi obținute rezultate satisfăcătoare.

În consecință, modelele propuse sunt BERT-base-uncased și DistilBERT-base-uncased pentru text, wav2vec2-base și DistilHuBERT pentru sunet, respectiv ViT-B/16 și MobileNetV3-Small pentru recunoașterea facială a emoțiilor. DistilBERT este o comparație potrivită cu BERT deoarece menține capacitatea lui BERT de a reprezenta textul, reducând în același timp cu aproximativ 40% numărul de parametri și aproape înjumătățind timpul de inferență. DistilHuBERT performează comparabil, folosind un număr de parametri de aproximativ patru ori mai mic prin distilare. În cazul modelelor pe imagini, am optat pentru o diferență foarte mare între modele, încercând să evidențiez punctul până la care se poate merge cu reducerea dimensiunii modelelor fără a pierde prea multă acuratețe.

## 2.4 Strategiile de fuziune implementate

Au fost implementate trei tehnici de fuziune a modalităților: fuziune târzie, fuziune intermediară și fuziune bazată pe porți. Fuziunea târzie combină probabilitățile softmax prin două metode, o medie aritmetică și o medie ponderată optimizată pe datele de validare, fără a fi necesară o reantrenare. Fuziunea intermediară extrage penultimele reprezentări vectoriale din rețelele preantrenate și antrenează un perceptron multistrat ușor (MLP), de proiecție. Fuziunea bazată pe porți este similară cu fuziunea târzie, însă ponderile sunt calculate pentru fiecare eșantion.

Această organizare permite compararea directă între modelele unimodale și cele multimodale, precum și între variantele complexe și cele eficiente. În acest fel, se poate observa nu doar dacă fuziunea îmbunătățește performanța, ci și dacă această îmbunătățire justifică resursele suplimentare necesare.

## 2.5 Metodele de explicabilitate utilizate

Fiecare metodă de explicabilitate a fost aleasă pentru a se potrivi modelului pe care se aplică. Pentru modelele text bazate pe transformeri, se folosește ocluzia tokenilor și LayerIntegratedGradients, cea din urmă determinând importanța fiecărui token prin aproximarea integralei gradientilor de-a lungul unei traiectorii de la o instanță de referință neutră la instanța analizată. Pentru audio se folosește o structură similară, având Integrated Gradients în pereche cu ocluzia temporală, iar pentru imagini Integrated Gradients este combinat cu Grad-CAM.

Aceste metode nu sunt folosite separat de evaluarea performanței, ci sunt integrate în interpretarea rezultatelor. Scopul este de a înțelege ce informații par să fie folosite de fiecare modalitate, unde apar punctele forte și limitele modelelor unimodale și cum se schimbă interpretarea atunci când predicțiile sunt combinate prin fuziune multimodală.

## **2.6 Măsurarea eficienței**

Eficiența a fost măsurată folosind mai multe metrici, unele având ca scop estimarea energiei electrice necesare adaptării modelelor pe setul de date MELD, iar altele având ca scop determinarea fezabilității acestor modele pe sisteme cu putere computațională limitată. În acest context, consumul de putere al plăcii video este eșantionat la intervale de o secundă în timpul antrenării prin intermediul utilitarului `nvidia-smi`, utilizând un fir de execuție secundar care rulează în paralel cu antrenarea. Energia totală de antrenare, exprimată în kWh, este derivată ca produs între consumul mediu de putere și durata antrenării.

Pe lângă consumul energetic, latența de inferență per eșantion este măsurată separat, pe o dimensiune a lotului egală cu 1, în mod determinist pe CPU. Această măsurătoare este relevantă pentru utilizarea modelelor în scenarii practice, mai ales pe dispozitive de tip edge, unde timpul rapid de inferență și dimensiunea redusă a modelului pot fi mai importante decât obținerea celui mai mare scor posibil.

### 3 Implementare și configurare experimentală

Implementarea sistemului de recunoaștere multimodală a emoțiilor a fost organizată ca un proiect Python modular, structurat în jurul setului de date MELD (Multimodal EmotionLines Dataset). Toate etapele experimentale, de la preprocesare până la fuziune și interpretabilitate, pot fi reproduse prin notebook-uri Jupyter și module sursă versionabile.

#### 3.1 Tehnologii utilizate

Întregul sistem a fost dezvoltat în Python 3.10, folosind PyTorch 2.7 ca principal cadru de lucru pentru învățare profundă [25]. Interfața cu modelele preantrenate este asigurată de biblioteca Hugging Face Transformers [26], care oferă arhitecturile BERT, DistilBERT, wav2vec2 și DistilHuBERT, precum și utilitare pentru tokenizare, extragere de caracteristici și salvare a modelelor în format safetensors. Modelele de imagine sunt furnizate de torchvision, în special ViT-B/16 și MobileNetV3-Small, iar procesarea semnalelor audio este realizată cu torchaudio.

Detectarea și alinierea fețelor în etapa de preprocesare video se bazează pe MTCNN din biblioteca facenet-pytorch. Scorul de calitate al cadrelor selectate este estimat cu modelul EfficientNet-B0, salvat ca enet\_b0\_8\_best\_afew, antrenat pe setul AFEW, un domeniu apropiat de cel al secvențelor video din MELD. Calculul metricilor de clasificare se realizează cu scikit-learn, iar vizualizările sunt generate cu matplotlib și seaborn.

Pentru interpretabilitatea modelelor au fost integrate două biblioteci specializate: Captum [27], folosită pentru Integrated Gradients și LayerIntegratedGradients, și pytorch-grad-cam, folosită pentru vizualizări de tip EigenCAM în cazul modelelor vizuale. Întreaga infrastructură experimentală, incluzând antrenarea, evaluarea, fuziunea și vizualizarea rezultatelor, este expusă prin notebook-uri Jupyter organizate secvențial după etapa de lucru.

#### 3.2 Structura implementării

Proiectul este organizat în trei directoare principale: src, notebooks și experiments. Directorul src conține logica reutilizabilă a aplicației, structurată pe submodule: config.py, data, models, training, evaluation, explainability.

O decizie importantă de proiectare a fost introducerea unui sistem de cache pentru reprezentările vectoriale. Penultimul strat al fiecărei rețele de bază antrenate este aplicat o singură dată pe toate partițiile setului de date, train, dev și test, iar rezultatele sunt salvate în fișiere .npz, câte un fișier pentru fiecare modalitate și fiecare partiție. Dimensiunile reprezentărilor stocate sunt 768 pentru BERT și ViT, 256 pentru wav2vec2 și DistilHuBERT, respectiv 1024 pentru MobileNetV3-Small. Fuziunea intermediară și fuziunea bazată pe porți operează exclusiv pe aceste reprezentări stocate, eliminând necesitatea rerulării rețelelor de bază și reducând timpul de antrenare al capetelor de fuziune la ordinul minutelor.

### 3.3 Antrenarea modelelor

Modelele de text utilizate în această lucrare, BERT-base-uncased, cu 109 milioane de parametri, respectiv DistilBERT-base-uncased, cu aproximativ 66 de milioane de parametri, au fost ajustate folosind `AutoModelForSequenceClassification` din Hugging Face. Configurația de antrenare utilizează optimizatorul AdamW, cu  $lr = 2 \times 10^{-5}$  și `weight_decay=0.01`, un planificator liniar al ratei de învățare cu încălzire pe (6%) din numărul total de pași și limitarea gradientului la norma 1.0. Tokenizarea trunchiază secvențele la 128 de tokeni, iar dimensiunea lotului este 16. Antrenarea are un maximum de 200 de epoci și folosește oprire timpurie, cu `patience=5`, pe baza scorului macro-F1 obținut pe setul de validare.

Modelele audio, `wav2vec2-base` și `DistilHuBERT`, urmează aceeași schemă de antrenare: AdamW,  $lr = 2 \times 10^{-5}$ , planificator liniar al ratei de învățare și oprire timpurie. Ajustările specifice modalității audio constau în eșantionarea semnalelor la 16 kHz, trunchierea acestora la maximum 10 secunde și procesarea cu `AutoFeatureExtractor`. Dimensiunea lotului este redusă la 8 din cauza dimensiunii mai mari a intrărilor audio.

Antrenarea modelelor pentru fețe, ViT-B/16 și `MobileNetV3-Small`, ambele preantrenate pe ImageNet, a necesitat mai multe măsuri împotriva supraînvățării, justificate de dimensiunea mai redusă a setului de date vizual. În testare, acesta conține 2.481 de mostre, față de 2.610 pentru text și audio, din cauza cadrelor în care nu a fost detectată nicio față. Pentru această modalitate, rețeaua de bază este înghețată în primele trei epoci, fiind antrenat doar capul de clasificare. De asemenea, se folosește o rată de învățare diferențială: rețeaua de bază primește  $lr \times 0.1$ , adică  $10^{-5}$ , iar capul de clasificare primește rata completă,  $10^{-4}$ . Ca regularizatori suplimentari, au fost folosite netezirea etichetelor, cu (`□=0.1`), și `RandomErasing`, cu (`p=0.3`). Pentru echilibrarea claselor pe durata antrenării a fost utilizat `WeightedRandomSampler`, având în vedere dezechilibrul puternic al MELD, unde clasa *neutral* reprezintă aproximativ 47% din date.

Capetele de fuziune sunt antrenate pe reprezentările vectoriale stocate în cache, obținute din rețelele de bază înghețate. Fuziunea târzie nu are parametri proprii, ci folosește media simplă sau media ponderată a vectorilor softmax unimodali, ponderile fiind optimizate prin căutare exhaustivă pe setul de validare. Fuziunea intermediară utilizează un model `ProjectionFusionMLP`, cu aproximativ 334.000 de parametri. Fiecare modalitate este proiectată la 128 de dimensiuni, după care concatenarea celor trei proiecții este procesată de un MLP cu 256 de neuroni ascunși și 7 clase de ieșire. Antrenarea capului de fuziune folosește AdamW, cu  $lr = 3 \times 10^{-4}$ , o planificare cosinusoidală a ratei de învățare și eliminarea aleatorie a modalităților, cu probabilitatea (`p=0.2`), pentru a crește robustețea față de modalitățile lipsă.

Fuziunea bazată pe porți este implementată în două variante. Prima variantă, bazată pe GMU, este `GatedFusionLight`, care calculează un scalar de poartă pentru fiecare modalitate prin softmax, permițând interpretarea relativă a contribuției fiecărei modalități. A doua variantă, `GatedFusionHeavy`, aplică un Transformer cross-modal cu două straturi, (`d_model=256`), 4

capete de atenție și o rețea feed-forward cu 512 neuroni peste cei trei tokeni de modalitate.

### 3.4 Metrici de evaluare

Evaluarea modelelor este realizată pe setul de test al MELD, care conține 2.610 enunțuri, cu o distribuție dezechilibrată: aproximativ 48% *neutral*, 15% *happiness*, 13% *anger* etc. Dezechilibrul accentuat al claselor face ca acuratețea simplă să fie o metrică insuficientă, deoarece un clasificator trivial care prezice mereu clasa *neutral* ar obține aproximativ 48% acuratețe.

Metrica principală utilizată pentru selecția modelelor salvate și pentru compararea arhitecturilor este macro-F1. Aceasta reprezintă media aritmetică a scorurilor F1 calculate pentru fiecare clasă, tratând toate cele șapte emoții în mod egal, indiferent de frecvența lor. Această alegere penalizează modelele care ignoră clasele rare, precum *disgust* și *fear*, și oferă o imagine mai echilibrată asupra performanței reale.

Raportul complet de evaluare include următoarele metrici:

- acuratețe globală – proporția predicțiilor corecte din totalul eșantioanelor de test;
- macro-F1 – media neponderată a scorurilor F1 pe clase, folosită ca metrică principală de selecție și comparare;
- F1 ponderat – media scorurilor F1 ponderată cu frecvența reală a fiecărei clase, reflectând performanța globală ținând cont de distribuția datelor;
- matricea de confuzie – vizualizată ca hartă de căldură normalizată pe fiecare clasă adevărată, pentru identificarea confuziilor sistematice între emoții semantic similare, precum *sadness* și *fear*;
- raportul de clasificare pe clasă – incluzând precision, recall și F1 individual, salvat atât în format text, cât și tabelar, pentru analiză detaliată.

Oprirea timpurie în antrenare se bazează exclusiv pe scorul macro-F1 obținut pe setul de validare, asigurând că modelul salvat este cel mai bun din perspectiva clasificării echilibrate, nu doar din perspectiva celei mai mici valori a pierderii. Monitorizarea consumului energetic al GPU-ului, exprimat în Wh per rulare, a fost adăugată ca metrică secundară pentru compararea eficienței modelelor complexe și eficiente.

## 4 Rezultate experimentale si evaluare

### 4.1 Performanta generala

Performanța tuturor modelelor antrenate pe setul de date MELD este prezentată în Tabelul 4.1. Configurația cu cele mai bune rezultate este cea în care sunt folosite modelele cu cei mai mulți parametri, rezultatele fiind fuzionate târziu printr-o medie ponderată, calculată pe datele de validare.

| Categorie                | Model                                       | Acuratețe | Macro-F1 | F1 ponderat |
|--------------------------|---------------------------------------------|-----------|----------|-------------|
| Unimodal                 | BERT-base                                   | 61.65     | 44.28    | 60.85       |
|                          | DistilBERT                                  | 58.77     | 41.23    | 58.85       |
|                          | wav2vec2-base                               | 42.68     | 25.07    | 42.73       |
|                          | ViT-B/16                                    | 34.26     | 23.89    | 35.58       |
|                          | DistilHuBERT                                | 42.99     | 22.26    | 40.96       |
|                          | MobileNetV3-Small                           | 23.78     | 18.26    | 21.76       |
| Fuziune târzie           | Fuziune târzie ponderată (complexă)         | 63.32     | 45.97    | 62.09       |
|                          | Fuziune târzie medie aritmetică (complexă)  | 61.83     | 41.68    | 59.59       |
|                          | Fuziune târzie ponderată (eficientă)        | 59.94     | 41.55    | 58.97       |
|                          | Fuziune târzie medie aritmetică (eficientă) | 60.02     | 40.67    | 58.47       |
| Fuziune intermediară MLP | Fuziune intermediară MLP (complexă)         | 61.91     | 45.33    | 61.63       |
|                          | Fuziune intermediară MLP (eficientă)        | 57.84     | 40.98    | 57.92       |
| Fuziune bazată pe porți  | Transformer cu porți (complex/complex)      | 58.85     | 43.22    | 59.65       |
|                          | Transformer cu porți (complex/eficient)     | 58.57     | 43.16    | 59.54       |
|                          | GMU cu porți (eficient/eficient)            | 56.99     | 41.57    | 58.01       |
|                          | GMU cu porți (eficient/complex)             | 56.07     | 40.90    | 56.69       |

Tabelul 2: Performanța pe setul de test a tuturor modelelor, sortate după scorul macro-F1.

Rezultatul confirmă faptul că trăsăturile multimodale sunt complementare și îmbunătățesc performanța față de orice arhitectură unimodală, având o creștere de aproximativ 1.7 puncte procentuale peste cel mai bun model unimodal, BERT.

Dintre abordările unimodale, cele bazate pe text au cele mai bune rezultate, indiferent de metrica aleasă. BERT obține un scor macro-F1 de 44.28%, rezultat care rămâne apropiat și în cazul variantei eficiente, DistilBERT, cu un scor de 41.23%. Acest lucru este în acord cu rezultatele obținute în literatura de specialitate. Modelele bazate pe sunet au performanțe substanțial mai slabe: wav2vec2 obține un scor macro-F1 de doar 25.07%, cu varianta eficientă la aproximativ 3 puncte procentuale mai jos. Acest lucru poate fi cauzat de mai mulți factori, precum suprapunerea vocilor, lungimea inconsistentă a înregistrărilor și, mai ales, sunetele adăugate în post-producție peste replicile personajelor.

Modelele faciale sunt cele mai puțin precise, cel mai bun model obținând un scor macro-F1 de doar 23.89%. Acest lucru este cel mai probabil cauzat de imprecizia datelor vizuale, luând în considerare etapa de preprocesare. Deși regula ca fața vorbitorului să ocupe cea mai mare parte din ecran este valabilă în majoritatea scenelor, ea nu se aplică întotdeauna, ducând la imagini imprecise. Pe lângă acest lucru, neclaritatea cauzată de mișcare (*motion blur*) și poziția fețelor

| Model                                   | Furie | Dezgust | Frică | Fericire | Neutru | Tristețe | Surpriză |
|-----------------------------------------|-------|---------|-------|----------|--------|----------|----------|
| BERT-base                               | 35.1  | 20.6    | 36.0  | 60.9     | 79.5   | 25.0     | 56.9     |
| DistilBERT                              | 34.5  | 19.1    | 14.0  | 61.2     | 72.9   | 27.9     | 62.3     |
| wav2vec2-base                           | 27.2  | 0.0     | 0.0   | 36.8     | 57.7   | 26.0     | 33.1     |
| DistilHuBERT                            | 31.0  | 0.0     | 0.0   | 22.9     | 65.8   | 13.9     | 23.8     |
| ViT-B/16                                | 30.8  | 6.1     | 4.1   | 52.7     | 35.7   | 32.5     | 19.1     |
| MobileNetV3                             | 24.7  | 18.2    | 12.2  | 65.8     | 11.9   | 40.8     | 5.6      |
| Fuziune târzie medie (complexă)         | 36.0  | 7.6     | 12.2  | 60.2     | 82.8   | 26.7     | 50.2     |
| Fuziune târzie medie (eficientă)        | 35.4  | 15.2    | 10.2  | 57.8     | 79.5   | 23.6     | 52.8     |
| Fuziune târzie ponderată (complexă)     | 40.2  | 16.7    | 22.4  | 65.6     | 80.4   | 28.8     | 55.8     |
| Fuziune târzie ponderată (eficientă)    | 34.1  | 16.7    | 12.2  | 59.6     | 77.2   | 27.7     | 57.3     |
| MLP (complex)                           | 47.6  | 15.2    | 32.7  | 59.4     | 76.3   | 30.9     | 58.1     |
| MLP (eficient)                          | 36.0  | 24.2    | 20.4  | 58.6     | 73.2   | 25.1     | 53.6     |
| Transformer cu porți (complex/complex)  | 42.4  | 25.8    | 26.5  | 51.4     | 73.1   | 36.6     | 56.2     |
| Transformer cu porți (complex/eficient) | 33.2  | 27.3    | 22.4  | 53.2     | 69.9   | 33.0     | 56.6     |
| GMU cu porți (eficient/complex)         | 45.4  | 21.2    | 30.6  | 57.1     | 70.4   | 33.5     | 56.2     |
| GMU cu porți (eficient/eficient)        | 35.1  | 28.8    | 32.7  | 59.9     | 70.1   | 27.2     | 53.9     |

Tabelul 3: Recall (%) per emoție.

din profil îngreunează sarcina modelelor de a învăța caracteristici specifice fiecărei emoții.

Cu privire la strategiile de fuziune, fuziunea intermediară între modelele complexe se clasează pe poziția a doua, doar puțin sub fuziunea târzie ponderată. În schimb, fuziunea bazată pe porți rămâne sub cel mai bun model unimodal, sugerând că, pe acest set de date în particular, mecanismele complexe de atenție nu oferă un avantaj clar.

În Tabelul 4.1 este prezentată o comparație între rezultatele obținute pentru fiecare clasă de emoții, pentru toate arhitecturile folosite în cadrul acestei lucrări. Pentru a înțelege mai bine performanța modelelor dincolo de scorul macro-F1, este utilă analizarea punctelor slabe ale fiecărei arhitecturi.

În cazul emoției *neutral*, aproape toate modelele bazate pe text și majoritatea strategiilor de fuziune ating cele mai mari valori de recall din întregul tabel. BERT și fuziunile multimodale depășesc constant pragul de 75–80%, ceea ce sugerează că emoțiile neutre sunt puternic asociate cu structura conversațională și cu lipsa unor indicii emoționale explicite. Modelele audio și vizuale performează mai slab pe această clasă, motiv pentru care putem concluziona că neutralitatea este mai puțin explicită în limbajul non-verbal.

Pentru emoția *happiness*, majoritatea modelelor obțin rezultate relativ ridicate, în special modelele bazate pe text, modelele faciale și strategiile de fuziune. Acest lucru este explicabil prin faptul că fericirea are adesea indicii lexicale, vocale și faciale mai clare decât emoțiile rare, precum *disgust* sau *fear*.

## 4.2 Analiza matricelor de confuzie

Pentru a completa analiza performanței generale, au fost analizate și matricile de confuzie ale modelelor. Această analiză este importantă deoarece setul de date MELD este puternic deze-

chilibrat, iar valorile agregate, precum acuratețea sau scorul macro-F1, nu arată întotdeauna ce tipuri de erori face fiecare model. În special, clasele rare, precum *dezgust* și *frică*, sunt dificil de detectat și pot fi ușor confundate cu emoții mai frecvente, precum *neutru*, *fericire* sau *furie*.

#### 4.2.1 Modelele unimodale complexe și eficiente

Prima comparație urmărește diferențele dintre modelele complexe și variantele lor eficiente pentru fiecare modalitate: text, audio și imagine.

Figura 2 arată că modelele text au cel mai stabil comportament dintre toate modalitățile. BERT-base păstrează o diagonală principală mai puternică și obține rezultate mai bune global, în special pe clasele mai dificile. DistilBERT rămâne apropiat pe clase precum *happiness*, *neutral* și *surprise*, dar pierde mai mult pe clase rare sau ambigue, precum *fear*. Acest lucru sugerează că modelul eficient păstrează o parte importantă din performanța lui BERT, însă distilarea reduce capacitatea de a modela contexte emoționale subtile.

În cazul modelelor audio, se evidențiază dificultatea acestei modalități de a separa clasele rare. Atât wav2vec2-base, cât și DistilHuBERT au rezultate slabe pentru *disgust* și *fear*, ceea ce indică faptul că aceste emoții nu sunt suficient de bine reprezentate doar prin semnalul audio. DistilHuBERT are o acuratețe apropiată de wav2vec2-base, însă acest lucru este obținut în principal printr-o tendință mai mare de a prezice clasa dominantă *neutral*.

Diferența dintre modelul complex și cel eficient este cea mai vizibilă în cazul modalității vizuale. ViT-B/16 este mai stabil decât MobileNetV3-Small, mai ales pentru clasa *neutral*. În schimb, MobileNetV3-Small tinde să supraestimeze clase vizuale mai expresive, precum *happiness* și *sadness*, dar pierde multe exemple neutre. Acest comportament arată că reducerea drastică a dimensiunii modelului afectează mai puternic modalitatea vizuală decât textul sau audio. O explicație posibilă este faptul că imaginile extrase din MELD conțin fețe necentrate, mișcare, expresii ambigue și cazuri în care vorbitorul nu este întotdeauna detectat perfect.

În ansamblu, comparația dintre modelele complexe și cele eficiente arată că reducerea dimensiunii modelelor nu afectează toate modalitățile în același mod. Pentru text, pierderea de performanță este relativ controlată. Pentru audio, modelul eficient păstrează acuratețea, dar nu prin generalizare, ci printr-o tendință de a prezice clasa predominantă. Pentru imagine, modelul eficient schimbă semnificativ distribuția predicțiilor, ceea ce duce la o scădere mai clară a performanței globale.

#### 4.2.2 Comparația dintre fuziunile complexe și eficiente

A doua comparație urmărește diferența dintre cea mai bună configurație de fuziune bazată pe modele complexe și varianta corespunzătoare bazată pe modele eficiente. În această lucrare, cea mai bună configurație globală este fuziunea târzie ponderată folosind modelele complexe. Aceasta este comparată cu fuziunea târzie ponderată folosind modelele eficiente, pentru a observa ce se pierde atunci când sunt înlocuite arhitecturile mari cu variante mai compacte.

## Matrici de confuzie unimodale - Light vs Heavy



Figura 2: Matrici de confuzie pentru toate modelele

### Matrici de confuzie - Fuziune ponderata tarzie (Light vs Heavy)




Figura 3: Matrici de confuzie pentru fuziunea târzie

Figura 3 arată că fuziunea târzie ponderată cu modele complexe are o diagonală principală mai stabilă și obține rezultate mai bune pentru majoritatea claselor. Diferența este importantă mai ales pentru clasele ambigue sau rare, precum *fear* și *anger*, unde modelele eficiente reușesc să păstreze mai multă informație utilă din fiecare modalitate. Varianta eficientă rămâne competitivă global, reușind chiar să depășească ușor modelele complexe, pierzând totuși pe clasele dominante.

Comparația dintre cele două fuziuni confirmă faptul că modelele eficiente sunt competitive la o fracțiune din costul computațional, mai ales considerând faptul că cele complexe au un scor ridicat de tendința de a prezice clasa dominantă.

Această analiză arată că fuziunea multimodală este utilă, dar nu elimină complet limitările modelelor de bază. Dacă o modalitate este slabă sau zgomotoasă, cum se întâmplă în special pentru audio și imagine, fuziunea trebuie să reducă impactul acesteia. Din acest motiv, fuziunea târzie ponderată funcționează mai bine decât media simplă: ea permite acordarea unei importanțe mai mari modalităților mai stabile și limitează influența celor mai zgomotoase.

În concluzie, matricile de confuzie arată că performanța globală trebuie interpretată împreună cu distribuția erorilor pe clase. Modelele text sunt cele mai stabile, modelele audio au dificultăți clare pe clase rare, iar modelele vizuale sunt cele mai sensibile la calitatea preprocesării. Fuziunea multimodală îmbunătățește rezultatele generale, însă cu un procent mic relativ la diferența dimensiunii modelelor.

## 4.3 Analiza XAI pe cazuri generale

Pentru a intelege mai bine motivul pentru care modelele iau deciziile pe care le iau, am folosit diverse tehnici de explicabilitate. Obiectivul acestei analize nu a fost doar de a analiza corectitudinea predictiilor, ci si de a identifica potentiale slabiciuni si sursele lor

### 4.3.1 Text

In figura 4 am folosit Integrated Gradients pentru a analiza contributia token-urilor. Se poate observa cum, in clasificarea replicii in categoria anger, o importanta foarte mare o are cuvantul "silliness". In schimb, in cazul replicii "I'm so sorry!", modelul interpreteaza cuvantul "sorry" ca semnalizand tristete. Este un caz clasic in care un cuvant isi schimba foarte mult semnificatia in functie de context, acesta putand fi sugerat prin indicii auditive sau vizuale. Acest lucru exemplifica clar faptul ca doar continutul unui dialog este insuficient pentru a recepta nuantele ce schimba sensul anumitor propozitii.




Figura 4: Integrated Gradients pe modele text

### 4.3.2 Audio

In figura 5 este evidentiata folosind Temporall Occlusion segmentele temporale care atunci cand au fost eliminate, increderea modelului in predictia sa a scazut semnificativ. Varfurile de importanta coincid cu o tonalitate mai joasa, o voce mai slaba. In schimb, segmentele aproape de finalul inregistrarii au o importanta mai scazuta, sugerand ca doar anumite puncte sunt relevante pentru o anumita emotie. Se pot observa totusi si scoruri negative pe alocuri, sugerand faptul ca unele secvente, daca ar fi inlaturate, ar imbunatati performanta. Ele contin cel mai probabil sunete adaugate in post-productie sau zgomote de fundal.

### 4.3.3 Imagine

Figura 6 reprezinta o identificare corecta a emotiei *Surprise*. Harta de atentie indica faptul ca modelul se concentreaza in mod special pe partea centrala si de sus a fetei, acordand importanta in mod special gurii si zonei ochilor. Acest comportament este in concordanta cu studiile psihologice care asociază emoția de surpriză cu ridicarea sprâncenelor și deschiderea accentuată




Figura 5: Ocluzie temporală pe modele audio

a ochilor, regiunea ochilor fiind raportată ca deosebit de importantă pentru detectarea surprizei [28, 29]. Concentrarea pe zonele importante sugerează faptul că modelul învață trasături faciale relevante emoțiilor și nu se bazează pe zgomot de fundal. Exemplul din dreapta arată un motiv elocvent pentru care detectarea emoțiilor este o sarcină dificilă și adesea subiectivă. Sunt emoții care împart foarte multe trasături faciale, ca în exemplul curent unde frica și surpriza sunt ambele asociate cu ochii mari și tensiune în musculatura feței. Modelul în continuare se concentrează pe trasături sugestive pentru emoții, dar este indus în eroare de similaritatea lor.



Figura 6: Grad-CAM pe modele faciale

## 4.4 Analiza eficienței

Referitor la eficiența energetică și de timp la inferență, în Tabelul 4.4 este o comparație pe fiecare tip de input între modelele eficiente și cele complexe care arată clar că cele eficiente reduc semnificativ resursele necesare față de variantele lor mai mari. Diferența dintre modele este relativ mică la text, medie la audio și extremă la modelele bazate pe imagini ale feței, alegere ce are ca scop evidențierea compromisului între eficiență și acuratețe la scări diferite.

Pentru text, DistilBERT este cea mai echilibrată alternativă: reduce timpul de inferență aproximativ la jumătate, în timp ce păstrează 93% din acuratețe. Diferența de eficiență energetică este importantă, dar nu extremă, ceea ce sugerează că textul este deja o modalitate relativ eficientă comparativ cu audio și față.

În cazul sunetului, diferența dintre modele este mai pronunțată. DistilHuBERT are un timp

de inferență de 3 ori mai rapid decât wav2vec2, și un consum de energie proporțional mai mic, arătând faptul că distilarea este foarte relevantă pentru modelele audio, care sunt mai costisitoare.

Cea mai mare diferență apare în analiza facială. MobileNetV3-Small are un timp de inferență de doar 0.48 ms, o diferență considerabilă față de cele 15 ms ale lui ViT-B/16. De asemenea, și energia consumată la antrenare scade considerabil. Pe de altă parte, aici se poate observa și diferența cea mai mare între performanța modelelor, cel eficient fiind la peste 5 procente sub modelul performant. MobileNetV3 este potrivit pentru dispozitivele în care energia și timpul de inferență trebuie să fie cât de mici posibil, dar acest lucru vine cu un cost considerabil în materie de acuratețe.

În ansamblu, rezultatele confirmă faptul că modelele compacte oferă reduceri majore de cost, mai ales pentru audio și față. Totuși, acest lucru încetează din a mai fi practic în momentul în care dimensiunea modelelor diferă prea mult.

| Modalitate | Model             | Inferență (ms/eșantion) | Antrenare (kWh) | Macro-F1 |
|------------|-------------------|-------------------------|-----------------|----------|
| Text       | BERT-base         | 11.55                   | 0.0207          | 44.28    |
|            | DistilBERT        | 5.82                    | 0.0143          | 41.23    |
| Audio      | wav2vec2-base     | 19.25                   | 0.3055          | 25.07    |
|            | DistilHuBERT      | 6.33                    | 0.1182          | 22.26    |
| Imagine    | ViT-B/16          | 15.01                   | 0.3389          | 23.89    |
|            | MobileNetV3-Small | 0.48                    | 0.0299          | 18.26    |

Tabelul 4: Eficiența modelelor unimodale: viteza de inferență, energia consumată la antrenare și scorul macro-F1 pe MELD.

## 5 Concluzii și direcții viitoare

Această lucrare investighează recunoașterea emoțiilor printr-o abordare multimodală aplicată pe setul de date MELD, combinând caracteristici textuale, audio și faciale, luând în considerare explicabilitatea și eficiența computațională a modelelor. Rezultatele experimentale arată că textul este cel mai puternic semnal, în timp ce partea audio și caracteristicile faciale rămân o provocare, în principal din cauza zgomotului prezent în date, a duratei scurte a replicilor, a râsetelor adăugate în post-producție, a detectării imperfecte a feței vorbitorului și a ambiguității conversațiilor în general.

Cu toate acestea, combinarea tuturor informațiilor duce la o îmbunătățire clară a performanței, sugerând complementaritatea indiciilor provenite din cele trei modalități. Compararea dintre modelele mai mari și variantele lor eficiente confirmă faptul că performanța ridicată poate fi obținută cu o reducere semnificativă a resurselor necesare antrenării și rulării acestor modele. Acest lucru indică faptul că acest compromis dintre acuratețe și eficiență este un criteriu important de luat în calcul atunci când vine vorba de implementarea unui astfel de sistem.

Ca direcții viitoare, mai multe aspecte pot fi îmbunătățite. În primul rând, modalitatea facială, care a obținut cele mai slabe rezultate, poate fi îmbunătățită prin extragerea mai precisă a fețelor vorbitorilor din cadru. Acest lucru poate fi realizat prin analizarea mișcărilor faciale în raport cu sunetul și prin identificarea vorbitorului pe baza mișcărilor gurii. O astfel de abordare ar duce la date mai curate și, în consecință, la modele mai precise.

Referitor la sunet, înlăturarea râsetelor de pe fundal ar putea aduce o îmbunătățire semnificativă. Componenta temporală și evoluția expresiilor faciale pe parcursul dialogului conțin informații utile prin care oamenii percep emoțiile în mod implicit, deci o analiză a modificării feței în timp ar putea aduce, de asemenea, îmbunătățiri, deși cu un cost computațional mai mare.

Un alt punct care merită investigat îl reprezintă metodele de fuziune mai avansate, care să acorde atenție modalităților mai puțin ambigue la nivelul fiecărui eșantion individual.

## Bibliografie

- [1] Soujanya Poria et al., „A review of affective computing: From unimodal analysis to multimodal fusion”, în *Information Fusion* 37 (2017), pp. 98–125, ISSN: 1566-2535, DOI: <https://doi.org/10.1016/j.inffus.2017.02.003>, URL: <https://www.sciencedirect.com/science/article/pii/S1566253517300738>.
- [2] George Trigeorgis et al., „Adieu features? End-to-end speech emotion recognition using a deep convolutional recurrent network”, în *2016 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2016, pp. 5200–5204, DOI: [10.1109/ICASSP.2016.7472669](https://doi.org/10.1109/ICASSP.2016.7472669).
- [3] Alexei Baevski et al., „wav2vec 2.0: A framework for self-supervised learning of speech representations”, în *Advances in neural information processing systems* 33 (2020), pp. 12449–12460, DOI: [10.48550/arXiv.2006.11477](https://doi.org/10.48550/arXiv.2006.11477).
- [4] Caifeng Shan, Shaogang Gong și Peter Mcowan, „Facial expression recognition based on Local Binary Patterns: A comprehensive study”, în *Image and Vision Computing* 27 (Mai 2009), pp. 803–816, DOI: [10.1016/j.imavis.2008.08.005](https://doi.org/10.1016/j.imavis.2008.08.005).
- [5] Shan Li și Weihong Deng, „Deep Facial Expression Recognition: A Survey”, în *CoRR* abs/1804.08348 (2018), arXiv: [1804.08348](https://arxiv.org/abs/1804.08348), URL: <http://arxiv.org/abs/1804.08348>.
- [6] Mingxing Tan și Quoc Le, „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”, în *Proceedings of the 36th International Conference on Machine Learning*, ed. de Kamalika Chaudhuri și Ruslan Salakhutdinov, vol. 97, Proceedings of Machine Learning Research, PMLR, Sept. 2019, pp. 6105–6114, URL: <https://proceedings.mlr.press/v97/tan19a.html>.
- [7] Saif M. Mohammad și Peter D. Turney, „Crowdsourcing a Word-Emotion Association Lexicon”, în *Computational Intelligence* 29.3 (2013), pp. 436–465, DOI: <https://doi.org/10.48550/arXiv.1308.6297>.
- [8] Jacob Devlin et al., „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, în *arXiv preprint arXiv:1810.04805* (2018), DOI: <https://doi.org/10.48550/arXiv.1810.04805>, URL: <https://arxiv.org/abs/1810.04805>.
- [9] Dorottya Demszyk et al., „GoEmotions: A Dataset of Fine-Grained Emotions”, în *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, ed. de Dan Jurafsky et al., Online: Association for Computational Linguistics, Iul. 2020, pp. 4040–4054, DOI: [10.18653/v1/2020.acl-main.372](https://doi.org/10.18653/v1/2020.acl-main.372), URL: <https://aclanthology.org/2020.acl-main.372/>.
- [10] Sander Koelstra et al., „DEAP: A Database for Emotion Analysis ;Using Physiological Signals”, în *IEEE Transactions on Affective Computing* 3.1 (2012), pp. 18–31, DOI: [10.1109/T-AFFC.2011.15](https://doi.org/10.1109/T-AFFC.2011.15).
- [11] Tengfei Song et al., „EEG Emotion Recognition Using Dynamical Graph Convolutional Neural Networks”, în *IEEE Transactions on Affective Computing* 11 (2020), pp. 532–541, URL: <https://api.semanticscholar.org/CorpusID:149023718>.
- [12] Riccardo Guidotti et al., „A Survey of Methods for Explaining Black Box Models”, în *ACM Computing Surveys* 51.5 (2018), DOI: [10.1145/3236009](https://doi.org/10.1145/3236009), URL: <https://doi.org/10.1145/3236009>.

- [13] Amina Adadi și Mohammed Berrada, „Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)”, în *IEEE Access* 6 (2018), pp. 52138–52160, DOI: [10.1109/ACCESS.2018.2870052](https://doi.org/10.1109/ACCESS.2018.2870052), URL: <https://doi.org/10.1109/ACCESS.2018.2870052>.
- [14] Marco Ribeiro, Sameer Singh și Carlos Guestrin, „“Why Should I Trust You?”: Explaining the Predictions of Any Classifier”, în *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, ed. de John DeNero, Mark Finlayson și Sravana Reddy, San Diego, California: Association for Computational Linguistics, Iun. 2016, pp. 97–101, DOI: [10.18653/v1/N16-3020](https://doi.org/10.18653/v1/N16-3020), URL: <https://aclanthology.org/N16-3020/>.
- [15] Emma Strubell, Ananya Ganesh și Andrew McCallum, „Energy and Policy Considerations for Deep Learning in NLP”, în *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, ed. de Anna Korhonen, David Traum și Lluís Màrquez, Florence, Italy: Association for Computational Linguistics, Iul. 2019, pp. 3645–3650, DOI: [10.18653/v1/P19-1355](https://doi.org/10.18653/v1/P19-1355), URL: <https://aclanthology.org/P19-1355/>.
- [16] Jiasi Chen și Xukan Ran, „Deep Learning With Edge Computing: A Review”, în *Proceedings of the IEEE* 107.8 (2019), pp. 1655–1674, DOI: [10.1109/JPROC.2019.2921977](https://doi.org/10.1109/JPROC.2019.2921977), URL: <https://doi.org/10.1109/JPROC.2019.2921977>.
- [17] Mukund Sundararajan, Ankur Taly și Qiqi Yan, „Axiomatic Attribution for Deep Networks”, în *Proceedings of the 34th International Conference on Machine Learning*, ed. de Doina Precup și Yee Whye Teh, vol. 70, Proceedings of Machine Learning Research, PMLR, Iun. 2017, pp. 3319–3328, URL: <https://proceedings.mlr.press/v70/sundararajan17a.html>.
- [18] Maksims Ivanovs, Roberts Kadikis și Kaspars Ozols, „Perturbation-based methods for explaining deep neural networks: A survey”, în *Pattern Recognition Letters* 150 (2021), pp. 228–234, ISSN: 0167-8655, DOI: [10.1016/j.patrec.2021.06.030](https://doi.org/10.1016/j.patrec.2021.06.030), URL: <https://doi.org/10.1016/j.patrec.2021.06.030>.
- [19] Ramprasaath R. Selvaraju et al., „Grad-CAM: Visual Explanations From Deep Networks via Gradient-Based Localization”, în *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, Oct. 2017.
- [20] Carlos Busso et al., „IEMOCAP: Interactive emotional dyadic motion capture database”, în *Language Resources and Evaluation* 42 (2008), pp. 335–359.
- [21] Soujanya Poria et al., „MELD: A Multimodal Emotion Lines Dataset in Conversations”, în *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 2019, pp. 527–536, DOI: [10.18653/v1/P19-1050](https://doi.org/10.18653/v1/P19-1050).
- [22] K. Zhang et al., „Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks”, în *IEEE Signal Processing Letters* 23.10 (Oct. 2016), pp. 1499–1503, DOI: [10.1109/LSP.2016.2603342](https://doi.org/10.1109/LSP.2016.2603342).
- [23] Andrey V. Savchenko, „HSEmotion: High-speed emotion recognition library”, în *Software Impacts* 14 (2022), p. 100433, DOI: [10.1016/j.simpa.2022.100433](https://doi.org/10.1016/j.simpa.2022.100433), URL: <https://doi.org/10.1016/j.simpa.2022.100433>.

- [24] Abhinav Dhall et al., „Collecting Large, Richly Annotated Facial-Expression Databases from Movies”, în *IEEE Multimedia* 19.3 (2012), pp. 34–41, DOI: [10.1109/MMUL.2012.26](https://doi.org/10.1109/MMUL.2012.26), URL: [https://users.cecs.anu.edu.au/~adhall/Dhall\\_Goecke\\_Lucey\\_Gedeon\\_M\\_2012.pdf](https://users.cecs.anu.edu.au/~adhall/Dhall_Goecke_Lucey_Gedeon_M_2012.pdf).
- [25] Adam Paszke et al., „PyTorch: An Imperative Style, High-Performance Deep Learning Library”, în *Advances in Neural Information Processing Systems*, vol. 32, 2019, URL: <https://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library>.
- [26] Thomas Wolf et al., „Transformers: State-of-the-Art Natural Language Processing”, în *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, Online: Association for Computational Linguistics, Oct. 2020, pp. 38–45, DOI: [10.18653/v1/2020.emnlp-demos.6](https://doi.org/10.18653/v1/2020.emnlp-demos.6), URL: <https://aclanthology.org/2020.emnlp-demos.6/>.
- [27] Narine Kokhlikyan et al., „Captum: A unified and generic model interpretability library for PyTorch”, în *arXiv preprint arXiv:2009.07896* (2020), URL: <https://arxiv.org/abs/2009.07896>.
- [28] Achim Schützwohl și Rainer Reisenzein, „Facial expressions in response to a highly surprising event exceeding the field of vision: A test of Darwin’s theory of surprise”, în *Evolution and Human Behavior* 33.6 (2012), pp. 657–664, DOI: [10.1016/j.evolhumbehav.2012.04.003](https://doi.org/10.1016/j.evolhumbehav.2012.04.003), URL: <https://doi.org/10.1016/j.evolhumbehav.2012.04.003>.
- [29] Emil Skog et al., „What surprises the Mona Lisa? The relative importance of the eyes and eyebrows for detecting surprise in briefly presented face stimuli”, în *Vision Research* 211 (2023), p. 108275, DOI: [10.1016/j.visres.2023.108275](https://doi.org/10.1016/j.visres.2023.108275), URL: <https://doi.org/10.1016/j.visres.2023.108275>.