




UNIVERSITATEA DIN BUCUREȘTI
FACULTATEA DE
MATEMATICĂ ȘI INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

RECUNOASTEREA EMOTIILOR

PRINTR-O ABORDARE MULTIMODALA

Coordonator științific:

Conf. Univ. Dr. Alexe Dumitru-Bogdan

Absolvent:

Ionascu Andrei

București, iunie 2026

Abstract

Pe masura ce inteligenta artificiala devine o componenta din ce in ce mai indispensabila in aplicatiile pe care oamenii le folosesc in fiecare zi, nevoia de sisteme care nu sunt doar precise, dar si eficiente din punct de vedere energetic si transparente cand vine vorba de deciziile pe care le iau a crescut considerabil. Aceasta lucrare exponeaza problema identificarii emotiilor umane printr-o abordare multimodala, analizand replici text, prozodie verbala si trasaturi faciale din setul de date MELD (Multimodal EmotionLines Dataset). Cercetarea exploreaza performantele obtinute de solutiile care integreaza un singur format de intrare, comparand ulterior imbunatatirile obtinute prin diverse metode de fuziune ale diferitelor surse de informatii. Spre deosebire de abordarile traditionale care prioritizeaza performanta, aceasta teza pune accentul pe compromisul dintre acuratete si eficienta energetica si de timp, in timp ce transparentizeaza modul in care diferitele modele iau decizii, prin metode de XAI (Explainable AI)

1 Introducere

1.1 Context si evolutie istorica

Recunoasterea emotiilor a evoluat de-a lungul timpului, plecand de la fluxuri conventionale, bazate pe caracteristici extrase manual pentru fiecare modalitate in parte, catre arhitecturi de tip deep learning, adesea pre-antrenate, capabile sa modeleze contextul, structura temporala si interactiunile cross-modale, dupa cum detaliaza [1]. Pe partea de audio si vorbire, domeniul a migrat de la descriptori clasici si clasificatori simpli catre modelele CNN-LSTM aplicate semnalului brut (raw waveform) [2] si, ulterior, catre codificatori de vorbire self-supervised, precum wave2vec 2.0 [3]. In vederea artificiala, traiectoria porneste de la descriptori de textura, precum Local Binary Patterns[4], si ajunge la retele convolutionale, retele bazate pe mecanisme de atentie[5] si modele FER optimizate pentru dispozitive de tip embedded[6]. Procesarea limbajului natural cu scopul recunoasterii emotiilor a evoluat de la sisteme bazate pe lexicon si seturi de date restranse[7], la preantrenarea slab supravegheata si fine-tuning a modelelor de tip Transformer [8] pe corpuri masive de date, cum este GoEmotions[9]. Pe langa modalitatile clasice, studiile recente exploreaza ramura de informatica fiziologica, unde lucrarile fundamentale s-au concentrat pe semnale EEG (Electroencefalograma) si periferice, utilizand seturi de date de referinta precum DEAP[10], progresand recent catre modele grafice care analizeaza topologia semnalelor cerebrale[11].

1.2 Motivatie

Motivatia acestei cercetari vine din faptul ca, odata cu integrarea functionalitatilor bazate pe inteligenta artificiala in tot mai multe produse software folosite in mod uzual de o tot mai mare parte din oameni, apare si nevoia de sisteme nu doar precise, dar si eficiente si de incredere.

1.3 Problema: Transparenta si eficienta

1.3.1 Problema ”Cutiei negre”

Vasta majoritate a publicatiilor stiintifice din domeniul recunoasterii emotiilor au ca singur scop obtinerea unei precizii cat mai mari. Totusi, complexitatea necesara maximizarii acuratetii duce adesea la modele de tip ”black-box”, al caror proces de gandire este prea complicat pentru a fi inteles chiar de catre oameni de stiinta, cu atat mai putin de catre utilizatorul obisnuit. Acest lucru duce la o lipsa de incredere in progresul tehnologic si la o reticenta in folosirea noilor produse.

1.3.2 Costul Energetic

Complexitatea modelelor State-Of-The-Art presupune, in majoritatea cazurilor, si un cost energetic proportional. Dincolo de amprenta ecologica, nevoia masiva de resurse computationale face imposibila executia acestor modele inafara unor centre de date specializate, fapt ce limiteaza drastic portabilitatea si ridica provocari privind confidentialitatea datelor. In plus, dezvoltarea acestor solutii implica bariere financiare semnificative, cauzate nu doar de infrastructura necesara procesarii, dar si de costurile logistice aferente stocarii si gestionarii unor seturi de date voluminoase.

1.4 Contributii si obiective

1.4.1 Integrarea multimodalitatii

TO BE CONTINUED ONCE FULLY IMPLEMENTED

1.4.2 Explicabilitatea rezultatelor

TO BE CONTINUED ONCE FULLY IMPLEMENTED

1.4.3 Compromisul dintre acuratete si eficienta energetica

TO BE CONTINUED ONCE FULLY IMPLEMENTED

2 Fundamentare teoretica si stadiul actual al cercetarii

2.1 Recunoasterea automata a emotiilor (FER/SER/MER)

2.2 Modalitati de intrare si procesarea semnalelor

2.2.1 Procesarea limbajului natural

2.2.2 Analiza prozodica

2.2.3 Analiza faciala

2.3 Arhitecturi de tip Deep Learning pentru date secventiale

2.4 Strategii de fuziune multimodala

2.5 Inteligenta artificiala explicabila (XAI)

2.6 Eficienta energetica si computationala in AI

2.7 Setul de date MELD si stadiul actual al domeniului

3 Metodologie

3.1 Analiza setului de date MELD

3.2 Preprocesarea datelor

3.3 Arhitecturi si modele propuse

3.4 Integrarea componentelor de explicabilitate

3.5 Strategia de masurare a eficientei

4 Implementarea sistemelor

4.1 Tehnologii utilizate

4.2 Detalii de implementare

4.3 Antrenarea modelelor

5 Rezultate experimentale si evaluare

5.1 Performanta bruta

5.2 Analiza XAI

5.3 Analiza eficientei

5.4 Discutii

6 Concluzii si directii viitoare

Cuprins

1	Introducere	ii
1.1	Context si evolutie istorica	ii
1.2	Motivatie	ii
1.3	Problema: Transparenta si eficienta	iii
1.3.1	Problema "Cutiei negre"	iii
1.3.2	Costul Energetic	iii
1.4	Contributii si obiective	iii
1.4.1	Integrarea multimodalitatii	iii
1.4.2	Explicabilitatea rezultatelor	iii
1.4.3	Compromisul dintre acuratete si eficienta energetica	iii
2	Fundamentare teoretica si stadiul actual al cercetarii	iv
2.1	Recunoasterea automata a emotiilor (FER/SER/MER)	iv
2.2	Modalitati de intrare si procesarea semnalelor	iv
2.2.1	Procesarea limbajului natural	iv
2.2.2	Analiza prozodica	iv
2.2.3	Analiza faciala	iv
2.3	Arhitecturi de tip Deep Learning pentru date secventiale	iv
2.4	Strategii de fuziune multimodala	iv
2.5	Inteligenta artificiala explicabila (XAI)	iv
2.6	Eficienta energetica si computationala in AI	iv
2.7	Setul de date MELD si stadiul actual al domeniului	iv
3	Metodologie	v
3.1	Analiza setului de date MELD	v
3.2	Preprocesarea datelor	v
3.3	Arhitecturi si modele propuse	v

3.4	Integrarea componentelor de explicabilitate	v
3.5	Strategia de masurare a eficientei	v
4	Implementarea sistemelor	vi
4.1	Tehnologii utilizate	vi
4.2	Detalii de implementare	vi
4.3	Antrenarea modelelor	vi
5	Rezultate experimentale si evaluare	vii
5.1	Performanta bruta	vii
5.2	Analiza XAI	vii
5.3	Analiza eficientei	vii
5.4	Discutii	vii
6	Concluzii si directii viitoare	viii

Bibliografie

- [1] S. Poria, E. Cambria, R. Bajpai și A. Hussain, „A review of affective computing: From unimodal analysis to multimodal fusion”, *Information Fusion*, vol. 37, pp. 98–125, 2017, ISSN: 1566-2535. DOI: <https://doi.org/10.1016/j.inffus.2017.02.003> adresa: <https://www.sciencedirect.com/science/article/pii/S1566253517300738>
- [2] G. Trigeorgis, F. Ringeval, R. Brueckner, E. Marchi, M. A. Nicolaou, B. Schuller și S. Zafeiriou, „Adieu features? End-to-end speech emotion recognition using a deep convolutional recurrent network”, în *2016 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2016, pp. 5200–5204. DOI: [10.1109/ICASSP.2016.7472669](https://doi.org/10.1109/ICASSP.2016.7472669)
- [3] A. Baevski, Y. Zhou, A. Mohamed și M. Auli, „wav2vec 2.0: A framework for self-supervised learning of speech representations”, *Advances in neural information processing systems*, vol. 33, pp. 12 449–12 460, 2020. DOI: [10.48550/arXiv.2006.11477](https://doi.org/10.48550/arXiv.2006.11477)
- [4] C. Shan, S. Gong și P. Mcowan, „Facial expression recognition based on Local Binary Patterns: A comprehensive study”, *Image and Vision Computing*, vol. 27, pp. 803–816, Mai 2009. DOI: [10.1016/j.imavis.2008.08.005](https://doi.org/10.1016/j.imavis.2008.08.005)
- [5] S. Li și W. Deng, „Deep facial expression recognition: A survey”, *IEEE Transactions on Affective Computing*, vol. 13, nr. 3, pp. 1195–1215, 2020. DOI: [10.48550/arXiv.1804.08348](https://doi.org/10.48550/arXiv.1804.08348)
- [6] M. Tan și Q. Le, „Efficientnet: Rethinking model scaling for convolutional neural networks”, în *International conference on machine learning*, PMLR, 2019, pp. 6105–6114. DOI: [10.48550/arXiv.1905.11946](https://doi.org/10.48550/arXiv.1905.11946)
- [7] S. M. Mohammad și P. D. Turney, „Crowdsourcing a Word-Emotion Association Lexicon”, *Computational Intelligence*, vol. 29, nr. 3, pp. 436–465, 2013. DOI: <https://doi.org/10.48550/arXiv.1308.6297>
- [8] J. Devlin, M.-W. Chang, K. Lee și K. Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, *arXiv preprint arXiv:1810.04805*,

2018. DOI: <https://doi.org/10.48550/arXiv.1810.04805> adresa: <https://arxiv.org/abs/1810.04805>
- [9] D. Demszky, D. Movshovitz-Attias, J. Ko, A. Cowen, G. Nemade și S. Ravi, „GoEmotions: A Dataset of Fine-Grained Emotions”, în *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, D. Jurafsky, J. Chai, N. Schluter și J. Tetreault, ed., Online: Association for Computational Linguistics, Iul. 2020, pp. 4040–4054. DOI: [10.18653/v1/2020.acl-main.372](https://doi.org/10.18653/v1/2020.acl-main.372) adresa: <https://aclanthology.org/2020.acl-main.372/>
- [10] S. Koelstra, C. Muhl, M. Soleymani, J.-S. Lee, A. Yazdani, T. Ebrahimi, T. Pun, A. Nijholt și I. Patras, „DEAP: A Database for Emotion Analysis ;Using Physiological Signals”, *IEEE Transactions on Affective Computing*, vol. 3, nr. 1, pp. 18–31, 2012. DOI: [10.1109/T-AFFC.2011.15](https://doi.org/10.1109/T-AFFC.2011.15)
- [11] T. Song, W. Zheng, P. Song și Z. Cui, „EEG Emotion Recognition Using Dynamical Graph Convolutional Neural Networks”, *IEEE Transactions on Affective Computing*, vol. 11, pp. 532–541, 2020. adresa: <https://api.semanticscholar.org/CorpusID:149023718>